

# 制御可能な動作生成のための条件付き残差学習

## Conditional Residual Learning for Controllable Motion Generation

水谷 圭

MIZUTANI Kei

(指導教員 境野 翔)

**Abstract** – Bilateral control-based imitation learning (BCIL) captures high-quality robot demonstrations containing both position and force information, yet it is tightly coupled to recording conditions: any change in object size, material, or desired placement requires new demonstrations and full retraining. This paper proposes a framework in which a user specifies a numerical label  $\mathbf{c}$  (the difference between a target output and the current output), and the robot autonomously generates a trajectory deviating from a base trajectory by the desired displacement without retraining. The framework leverages iterative learning control (ILC), which updates the label across trials to converge the actual output to the target. Stable ILC convergence requires the label-to-output mapping to exhibit global monotonicity, uniform sensitivity, and low inter-trial inference variance. Our central hypothesis is that predicting only the residual  $\Delta\xi$  from the base trajectory, rather than the full corrected trajectory, reinforces all three properties. Residual training data are collected efficiently via Motion ReTouch, a post-editing technology based on four-channel bilateral control. A preliminary pick-and-place experiment compares direct and residual prediction models. The residual model achieves  $R^2 \approx 0.87$  and Spearman  $\rho \approx 0.94$ , strongly supporting the hypothesis. Remaining challenges include a systematic offset at label  $\mathbf{c} = \mathbf{0}$  and label-dependent deviation during the pick phase.

## 1 序論

近年、4ch バイラテラル制御に基づく模倣学習 (Bilateral Control-based Imitation Learning; BCIL) が注目されている [1]. バイラテラル制御では人間が操作するリーダーと、その動作に追従するフォロワの2台のロボット間で、位置と力の2つの情報を同期するように制御する。操作者がフォロワロボットを遠隔操作する際の位置と力の両方が記録されるため、力加減を要する接触タスクでも高品質なデモンストレーションデータが得られる。このデータからニューラルネットワーク (Neural Network; NN) を学習させることで、ロボットは多様な操作を自律実行できるようになる [2, 3].

しかし BCIL は収録データの条件に強く依存するという課題がある。実運用ではワークのサイズ・材質の変化や、ブレース位置・締め付けトルクの微調整といった条件変更が頻繁に発生する。このような変更のたびに新たなデモンストレーションを収録して再学習することは、時間とコストの面で大きな負担となる。また、“3.5 Nm で締め付ける” や “現在より 5 mm 右へ置く” といった定量的な数値指定で出力を制御する仕組みは、既存の BCIL では提供されていない [4].

本研究では、数値ラベル  $\mathbf{c}$  (目標値と現在値との差分) を指定することで、ベース軌道から所望の変位だけずれた軌道を生成し、ロボットを自律動作させる枠組みを提案する。提案フレームワークでは、反

復学習制御 (Iterative Learning Control; ILC) [5] の考え方を応用する。これは、同一動作を反復する中で前試行の制御エラーを次試行の入力にフィードバックし、動的システムの不確かさを排して目標軌道へ漸近収束させる手法である。具体的には、人間がチューニングした固定学習ゲイン  $\mathbf{K}$  を用いて、試行  $k$  における実行結果  $\mathbf{v}^{(k)}$  と目標値  $\mathbf{v}^*$  の誤差から、次試行のラベルを  $\mathbf{c}^{(k+1)} = \mathbf{c}^{(k)} + \mathbf{K}(\mathbf{v}^* - \mathbf{v}^{(k)})$  とし逐次更新し、実機出力を目標値へと収束させる。

この固定ゲイン ILC が安定して収束するためには、入力 (ラベル  $\mathbf{c}$ ) から出力 (実際の出力  $\mathbf{v}$ ) までの真の伝達特性を  $f(\mathbf{c})$  としたとき、縮小写像の原理から全領域で  $\|\mathbf{I} - \mathbf{K}\nabla_{\mathbf{c}}f(\mathbf{c})\| < 1$  を満たす必要がある。具体的には、以下の 3 つの条件が同時に満たされることが本手法の成立要件となる。

1. **広域的な単調増加性**： ラベルの増減に対して、実際の実行結果の符号が反転することなく常に同じ方向へ追従すること ( $\nabla_{\mathbf{c}}f(\mathbf{c}) > 0$ )。
2. **傾きの均一性**： 局所的な飽和や急激な曲率変化がなく、全域にわたって傾きがほぼ一定であること。これによって、固定の学習ゲイン  $\mathbf{K}$  が全領域で適合する。
3. **低い試行間推論分散**： モデル由来の予測のばらつきが、固定ゲインによる毎試行の修正ステップ幅に対して十分に小さいこと。これにより、ノイズに埋もれることなく定常エラーをなめらかに排除できる。

提案手法の中核となる仮説は、動作全体を直接予測するよりも、ベース動作からの差分 (残差)  $\Delta\xi$  だけを予測する方が、モデルの決定性を高めて推論分散を抑えられるとともに、ラベルと出力の間の線形性・単調増加性が強まる、というものである。この仮説が成立すれば、少量の学習データかつ再学習なしに、固定ゲイン ILC による安定かつ高精度な数値制御が実現できる。

残差  $\Delta\xi$  の訓練データ収集には、Motion ReTouch [6] を活用する。Motion ReTouch は、4ch バイラテラル制御によって得られたロボットの動作データを事後的に修正するための手法である。

従来の位置情報のみを書き換える修正方法とは異なり、複数台のロボットを同期する制御マルチラテラル制御と、記録した位置・力指令値の再現再生を行うモーションコピーシステムを組み合わせることで、位置だけでなく力の情報も含めて遡及的に修正・補正できる。具体的には、3 台構成のマルチラテラル制御構造を応用し、すでに記録された過去の動作データ (修正前データ) に対して、オペレーターが後から介入して新しい指令値をブレンドすることで、位置と力双方のシームレスな書き換えを実現する。この仕組みによって、位置だけでなく力情報を含む残差  $\Delta\xi$  を効率的に収集できる。本研究では Motion ReTouch を軌道後修正の目的には用いず、残差の訓練データを収集する手段として位置づける。

本稿では、上記の仮説を実験的に検証するため、積み木のピックアンドプレースタスクを用いた予備実験を行った。修正後の動作を直接予測するモデル (Direct w/ image) と残差を予測するモデル (Residual w/ image, Residual w/o image) を比較し、ラベルに対する単調増加性を定量的に評価した。

本稿の構成は以下のとおりである。2 節で関連研究を概観し、3 節で提案手法の枠組みを説明する。4 節で予備実験の設定を述べ、5 節で結果と考察を示す。6 節でまとめと今後の課題を述べる。

## 2 関連研究

### 2.1 条件付き動作生成

BCIL に条件変数を導入する試みとして、Bi-LAT [4] がある。Bi-LAT は自然言語を条件として力プロファイルを変調した動作を生成でき、“softly” や “strongly” のような指示で把持力を調整できる点で大きな進展である。しかし言語によるラベルは定性的なカテゴリに留まり、“3.5 Nm で締め付ける” のような定量的な数値指定ができない。また離散カテゴリ間の補間は困難で、新しい力レベルには再学習が必要になる。

ゴール条件付き模倣学習 [7] は、ゴール画像やゴール位置ベクトルといった目標状態を条件として与え、そこへ到達する軌道を生成するアプローチである。

ゴールを数値で指定できる点は本研究と方向性が近いが、力情報を含む条件指定は対象外であり、“現在位置から 5mm 右へ”のような操作量ベースの指定とも設計思想が異なる。

## 2.2 残差ベースのロボット学習

残差強化学習 [8] は、ベースポリシーに対する残差補正を強化学習で学習する手法であり、少数の補正を効率的に学習できる利点がある。また、Davchev らの Residual Learning from Demonstration [9] は、動的動作プリミティブベースのポリシーに対して残差をデモンストレーションから学習することで、接触を含む操作タスクに適応させる手法を提案している。さらに TER-DAGger [10] は DAGger フレームワークに残差学習を組み込み、力認識フィードバックによって接触タスクの成功率を改善している。

これらの手法は残差という概念において本研究と方向性が共通しているが、残差強化学習はオンラインの強化学習探索を、TER-DAGger はロールアウト中の人間介入を必要とするため、安全性の確保や事前に定めた数値目標への直接収束という点で課題がある。本研究はオフラインの収録データのみを用い、かつ定量的なラベルと出力の間の単調増加性を活用して ILC による数値収束を目指す点で、既存の残差学習系手法と異なる。

## 3 提案手法

### 3.1 基本コンセプトと仮説

本研究は、数値ラベル  $c$  (目標値と現在の出力値の差分) を指定することで、ベース動作データ  $\xi_{\text{base}}$  から所望の変位だけずれた動作をロボットに自律実行させることを目的とする。ここで「動作データ」とは、位置・速度・トルクを含む関節状態の時系列  $\xi \in \mathbb{R}^{T \times D}$  を指す。ただし、 $T$  は動作の全タイムステップ数、 $D$  は関節の物理状態の総次元数である。

提案フレームワークでは、ILC によってラベルと実際の出力値を反復的に収束させることを想定している。このとき、序論で述べた縮小写像の原理に基づき、ラベル  $c$  の増減に対して実際の制御出力  $v(\xi)$  が極性を反転させることなく追従する「広域的な単調増加性」、全域で感度が一定である「傾きの均一性」、

表 1: 記号定義

| 記号                                                    | 定義                                                    |
|-------------------------------------------------------|-------------------------------------------------------|
| $\xi_{\text{base}} \in \mathbb{R}^{T \times D}$       | ベース動作データ                                              |
| $\xi_{\text{corr}}^{(c)} \in \mathbb{R}^{T \times D}$ | ラベル $c$ に対応する修正後動作データ                                 |
| $\Delta\xi^{(c)} \in \mathbb{R}^{T \times D}$         | 教師残差 $:= \xi_{\text{corr}}^{(c)} - \xi_{\text{base}}$ |
| $c \in \mathbb{R}^m$                                  | 試行レベルのラベル                                             |
| $v(\xi) \in \mathbb{R}^m$                             | 動作データ $\xi$ の評価量                                      |
| $v^* \in \mathbb{R}^m$                                | 目標値                                                   |

および固定の学習ゲインによる収束の妨げとならない「低い試行間推論分散」の 3 つの性質が同時に満たされることが、ILC 収束の前提条件となる。

本研究の仮説は、動作データ全体  $\xi$  を直接予測するより、ベース動作データからの残差  $\Delta\xi$  だけを予測する方が、これら 3 つの性質が強まる、というものである。ベース動作データ  $\xi_{\text{base}}$  という固定のアンカーが存在することで、NN が学習すべき変化量は小さくなり、ラベルと出力の対応関係がシンプルになると考えられる。この仮説が成立することを、本稿の予備実験で検証する。

提案フレームワークは次の三段構成をとる。

1. **残差データの収集**: Motion Retouch [6] を用いて、ベース動作データに対する修正後動作データ  $\xi_{\text{corr}}$  を収録し、ラベル  $c$  に対応する教師残差  $\Delta\xi^{(c)} = \xi_{\text{corr}}^{(c)} - \xi_{\text{base}}$  を得る。
2. **残差 NN の学習**: ラベル  $c$  を条件として、観測から  $\Delta\xi^{(c)}$  を予測する残差 NN を学習する。
3. **ILC による反復収束**: 学習済み NN を用いてロボットを実行し、出力誤差をラベルに反映させる更新則を反復することで、目標値への収束を実現する。

### 3.2 問題設定

記号を表 1 に定義する。ラベルは目標値と現在の出力値の差分として定義する：

$$c = v^* - v(\xi_{\text{base}}), \quad (1)$$

ここで  $v(\xi)$  は動作データ  $\xi$  を実行したときのブレース位置・最終トルクなどの評価量、 $v^*$  は目標値、 $m$  はその次元数である。

### 3.3 モデルアーキテクチャ

本研究では、Transformer デコーダに基づく模倣学習モデルを用いる。入力は過去  $L$  ステップのフォロワームの関節状態系列（各ステップで角度・角速度・トルクを結合した  $d_a$  次元ベクトル）、現在時刻のカメラ画像、および数値ラベル  $\mathbf{c}$  である。出力は将来  $L$  ステップの関節状態の予測残差系列  $\Delta\hat{\mathbf{y}} \in \mathbb{R}^{L \times d_a}$  である。

状態系列は線形層と正弦波位置エンコーディングによりトークン化し、Transformer デコーダのクエリとして用いる。画像は固定重みの ResNet-50 [11] で特徴マップを抽出し、Transformer エンコーダを経てメモリトークン列に変換する。画像を使用しない場合は、学習可能なメモリトークン列をそのままキー・バリューとして用いる。数値ラベル  $\mathbf{c}$  は状態系列と結合して入力する。学習は予測と教師信号の MSE 損失で行う。

推論時には Action Chunking with Transformers [12] に倣った Temporal Ensemble を適用し、ローリングバッファに蓄積した予測の平均によって推論ノイズを低減する。最終的な出力軌道  $\hat{\mathbf{y}}$  は、ベース動作データ  $\xi_{\text{base}}$  の対応するステップの値に、予測残差  $\Delta\hat{\mathbf{y}}$  に Temporal Ensemble をかけたものを加算することで得られる。

## 4 予備実験

### 4.1 検証仮説と実験設計

3 節の仮説、すなわち“残差予測によって ILC の収束を満たすための性質が強まる”ことを実験的に検証する。評価には積み木のピックアンドプレースタスクを用い、プレース位置の変位  $\mathbf{c} = [c_x, c_y]$ （各軸方向への移動量、単位 mm）をラベルとして与えたとき、実際のプレース変位がラベルに対してどのように変化するかを定量的に検証した。

### 4.2 学習データの収集

まず、“掴んだ積み木をそのまま置く”基準動作をベース動作データとして収録した。次に Motion Retouch を用いて、プレース位置を  $X \cdot Y$  方向にそれぞれ  $\pm 5$  mm ずらした 8 箇所と、何も修正しなかった場合の 1 箇所、計 9 箇所に対して各 5 回の修

正動作を収録し、合計 45 本のデータを収集した。各修正動作にラベル  $\mathbf{c} = [c_x, c_y]$  を付与し、ベース動作データとの差分  $\Delta\xi^{(c)}$  を教師残差とした。

### 4.3 検証モデル

表 2 に示す 3 モデルを比較した。Direct w/ image はロボットの観測とラベルから修正後動作データを直接予測する。Residual w/ image と Residual w/o image は残差  $\Delta\xi$  を予測し、実行時はモーションコピーで再生したベース動作データに残差を加算することで動作を生成する。モーションコピーとは、ベース動作データから得られた関節角指令値をそのままロボットに入力して動作を再現するシステムであり、本研究ではラベル  $\mathbf{c} = [0, 0]$  の補正なしに対応する動作の基準として機能する。ハードウェア再現精度の上限を確認するため、モーションコピー単体 (Motion Copy) の計測値も評価基準として用いた。

### 4.4 評価方法と試行数

検証ラベルは、各成分が  $\{-7, -5, -3, 0, 3, 5, 7\}$  の 7 値をとる 2 次元格子のうち、原点・各座標軸・対角線上に配置した 25 種類とした。把持動作が成立しない組み合わせはモデルごとに除外している (Direct w/ image : 4 ラベル除外, 105 試行; Residual w/o image : 2 ラベル除外, 115 試行; Residual w/ image : 全ラベル実施, 125 試行)。

評価指標として以下を用いた：

- ラベルと実変位の決定係数  $R^2$  および Spearman 順位相関係数  $\rho$  (単調増加性の指標)
- ラベル  $\mathbf{c} = [0, 0]$  時のプレース位置オフセット (残差ゼロの再現精度)
- 同一ラベル内の試行間標準偏差  $\sigma$  (再現性)
- プレース・ピック時の手先姿勢偏差

## 5 実験結果と考察

### 5.1 ラベル追従性

各モデルについて、ラベルと実際のプレース変位の相関を図 1 および表 3 に示す。

図 1 および表 3 に示すように、Residual w/ image は  $c_x$  方向に  $\rho = 0.97$ ,  $R^2 = 0.94$  と高い

表 2: 検証モデルの一覧

| モデル名               | 入力          | 出力             | 特徴           |
|--------------------|-------------|----------------|--------------|
| Direct w/ image    | 関節状態・画像・ラベル | 絶対値（修正後）       | 全ステップを NN 予測 |
| Residual w/ image  | 関節状態・画像・ラベル | 残差 $\Delta\xi$ | ベース再生+残差加算   |
| Residual w/o image | 関節状態・ラベル    | 残差 $\Delta\xi$ | 画像入力なし       |

表 3: ラベル追従性（決定係数  $R^2$  および Spearman 相関  $\rho$ ）

| モデル                | $R^2 (c_x)$ | $R^2 (c_y)$ | $\rho (c_x)$ | $\rho (c_y)$ |
|--------------------|-------------|-------------|--------------|--------------|
| Direct w/ image    | 0.56        | 0.50        | 0.66         | 0.76         |
| Residual w/ image  | <b>0.94</b> | <b>0.78</b> | <b>0.97</b>  | <b>0.85</b>  |
| Residual w/o image | 0.72        | 0.38        | 0.84         | 0.72         |




図 1: ラベルとプレース変位の関係（各モデルの散布図と回帰直線）

単調追従性を示した。これは 3 節の仮説 — 残差予測によって単調増加性が強まる — を実験的に支持する結果である。Residual w/o image も  $c_x$  方向に  $\rho = 0.84$ ,  $R^2 = 0.72$  と中程度の追従性を示し、画像なしの軽量構成でも有効であることが確認された。一方, Direct w/ image では  $R^2 = 0.56$  にとどまり, フルシーケンス予測では単調性の実現が難しいことが示された。また  $c_y$  方向は全モデルで相関がやや低く,  $c_y$  方向の制御精度の向上が今後の課題である。

## 5.2 ラベル $c = [0, 0]$ 時の系統バイアス

ラベル  $c = [0, 0]$  を与えた際の各モデルのプレース位置分布を図 2 に示す。モーションコピーの平均プレース位置を基準点 ( $p_{\text{ref}}$ ) とし, 各モデルの平均位置とのオフセットを表 4 に示す。

Residual w/ image および Residual w/o image はそれぞれ 18.1mm, 13.3mm の系統的な




図 2:  $c = [0, 0]$  時のプレース位置分布（ラベル座標系）。+ はモーションコピーの平均位置（基準点  $(0, 0)$ ）を示す。

オフセットが生じており, ラベル  $[0, 0]$  に対して残差ゼロを正確に学習できていないことを示す。この

表 4:  $c = [0, 0]$  時のプレース位置オフセットと試行間標準偏差

| モデル                | $n$ | オフセット [mm]  | $\sigma_{c_x}/\sigma_{c_y}$ [mm] |
|--------------------|-----|-------------|----------------------------------|
| Motion Copy        | 5   | $\approx 0$ | 0.27 / 0.09                      |
| Direct w/ image    | 5   | 10.3        | 8.24 / 5.83                      |
| Residual w/ image  | 5   | 18.1        | 0.99 / 0.43                      |
| Residual w/o image | 5   | 13.3        | 0.59 / 0.45                      |

バイアスは Direct w/ image の 10.3mm より大きく、残差モデルの構造的な弱点といえる。一方、試行間ばらつき ( $\sigma_{c_x}/\sigma_{c_y}$ ) は残差モデルで 0.99/0.43 mm および 0.59/0.45 mm と非常に小さく、Direct w/ image の 8.24/5.83 mm に対して高い再現性を示している。このバイアスは、ILC ループによる反復修正で吸収できる可能性があり、今後の検証課題である。

### 5.3 試行間再現性 (同一ラベル内標準偏差)

各モデルの同一ラベル内標準偏差  $\sigma_{\Delta x}$ ,  $\sigma_{\Delta y}$  の全ラベル平均を図 3 に示す。

Motion Copy ( $\sigma_{c_x} \approx 0.30$  mm,  $\sigma_{c_y} \approx 0.21$  mm) はハードウェア再現精度の上限を示す。Direct w/ image はこれより 1 桁以上大きい  $\sigma_{c_x} \approx 10.2$  mm,  $\sigma_{c_y} \approx 9.1$  mm を示し、フルシーケンス予測では推論ノイズが支配的であることが確認された。Residual w/ image は  $\sigma_{c_x} \approx 2.1$  mm,  $\sigma_{c_y} \approx 2.1$  mm と Direct w/ image より大幅に改善されているが、Residual w/o image ( $\sigma_{c_x} \approx 0.75$  mm,  $\sigma_{c_y} \approx 0.57$  mm) はさらに小さく、モーションコピー基準に近い再現性を示した。画像ありモデルでのばらつき増大は、照明・視点の微小変動によって画像特徴量が変動し、推論ノイズが増大したためと考えられる。

### 5.4 ピック時の手先位置偏差

ロボットはラベル  $c$  によってプレース位置のみを変えることが意図されており、ピック動作は全ラベルで同一であるべきである。しかし、図 4 に示すように、すべての学習モデルでラベル値に依存したピック位置のずれが観測された。

訓練ラベルは  $\{0, \pm 5\} \times \{0, \pm 5\}$  の 9 種類であり、ヒートマップ上の  $\pm 7$  対角ラベルは訓練分布外 (OOD) に相当する。表 5 に訓練範囲内 (In-dist) と OOD ラベルでのピック位置偏差を示す。

表 5: ピック位置偏差 (モーションコピー基準からのユークリッド距離の平均)

| モデル                | In-dist [mm] | OOD [mm] |
|--------------------|--------------|----------|
| Direct w/ image    | 7.3          | 10.8     |
| Residual w/ image  | 12.4         | 23.8     |
| Residual w/o image | 12.3         | 22.6     |

残差モデルでは In-dist でも 12 mm 程度のピック位置ずれが生じており、OOD ラベルではさらに 23 mm 程度まで増大する。これは、学習した残差  $\Delta \xi$  がピック段階の動作にも影響を及ぼしているためと考えられる。理想的には残差はプレース前の特定区間にのみ作用すべきだが、現状ではシーケンス全体に残差が加算されているため、ピック動作も変位してしまっている。一方、Direct w/ image は残差ではなく絶対値を予測するため、ピック段階への干渉が相対的に少ないが、その代わりラベル追従性が低い。プレース区間限定の残差加算、もしくはピック・プレース動作の明示的な分離モデリングといった、ピック段階への残差干渉を抑制するためのアーキテクチャ改良が今後の課題として挙げられる。

## 6 まとめと今後の課題

本研究では、数値ラベル  $c$  を指定するだけでベース動作データから所望の修正量だけずれた動作をロボットに実行させるフレームワークを提案した。このフレームワークでは、固定ゲイン ILC による数値収束の前提条件として「広域的な単調増加性」「傾きの均一性」「低い試行間推論分散」の 3 つの性質が必要であり、“軌道全体の絶対値を予測するよりも残差  $\Delta \xi$  を予測する方が、これらの性質が強まる”という仮説を立てた。

この仮説を検証するため、積み木のピックアンドプレースタスクを用いた予備実験を行った。画像ありの残差予測モデル (Residual w/ image) は  $c_x$  方向で Spearman 順位相関  $\rho = 0.97$ , 決定係数  $R^2 = 0.94$  を達成し、直接予測モデル ( $\rho = 0.66$ ,  $R^2 = 0.56$ ) と比べて大幅に高い単調追従性と傾きの均一性を示した。これにより、仮説を実験的に支持する結果が得られた。

一方、実機 ILC ループへの適用に向けて、以下の




図 3: 同一ラベル内ブレース変位標準偏差の比較。破線はモーションコピーの基準値を示す。




図 4: ラベル空間 ( $c_x, c_y$ ) 上のピック位置偏差ヒートマップ (モーションコピー平均ピック位置からのユークリッド距離)。灰色セルは未試行ラベルを示す。

2 点が今後の改善課題として明確になった：

(a)  $c = [0, 0]$  時の系統バイアスと推論分散：残差モデルではラベルをゼロにして補正なしを指示した状態でも 13~18mm の系統的なオフセットが生じており、さらに画像ありモデルでは試行間の推論分散が  $\sigma \approx 3 \sim 4$  mm と大きい。系統バイアス自体は固定ゲイン ILC の反復補正によって理論上吸収可能であるが、高い推論分散は ILC の収束を阻害するリスクがある。これに対し、画像を除外した残差モデル (Residual w/o image) では傾きの均一性を維持したまま分散を  $\sigma \approx 1$  mm に抑制できることを確認しており、本モデルの採用や損失関数への  $c = \mathbf{0}$  時のペナルティ追加が有効と考えられる。

(b) ピック段階への残差干渉：残差モデルでは、ブ

レース位置のみを変えることが意図されているにもかかわらず、ピック時の手先状態がラベルに依存してずれることが確認された (In-dist で  $\approx 12$  mm, OOD で  $\approx 23$  mm)。この問題に対しては残差加算をブレース区間に限定するか、ピック・ブレースを分離モデリングすることが有効と考えられる。

今後の方針として、Residual w/o image モデルをベースとした固定ゲイン ILC ループの実装によるバイアスの自動収束、ブレース区間限定の残差加算によるピック干渉の抑制、および位置だけでなく力情報を含む接触タスクへの展開を予定している。

## 参考文献

- [1] Ayumu Sasagawa, Kazuki Fujimoto, Sho Sakaino, and Toshiaki Tsuji. Imitation learning based on bilateral control for human – robot cooperation. *IEEE Robotics and Automation Letters*, Vol. 5, No. 4, pp. 6169–6176, 2020.
- [2] Thanpimon Buamanee, Masato Kobayashi, Yuki Uranishi, and Haruo Takemura. Bi-act: Bilateral control-based imitation learning via action chunking with transformer. In *2024 IEEE International Conference on Advanced Intelligent Mechatronics (AIM)*, pp. 410–415, 2024.
- [3] Yuki Saigusa, Ayumu Sasagawa, Sho Sakaino, and Toshiaki Tsuji. Imitation learning for variable speed motion generation over multiple actions. In *IECON 2021 – 47th Annual Conference of the IEEE Industrial Electronics Society*, pp. 1–6, 2021.
- [4] Takumi Kobayashi, Masato Kobayashi, Thanpimon Buamanee, and Yuki Uranishi. Bi-lat: Bilateral control-based imitation learning via natural language and action chunking with transformers. In *2025 34th IEEE International Conference on Robot and Human Interactive Communication (RO-MAN)*, pp. 1609–1616, 2025.
- [5] Suguru Arimoto, Sadao Kawamura, and Fumio Miyazaki. Bettering operation of robots by learning. *Journal of Robotic Systems*, Vol. 1, No. 2, pp. 123–140, 1984.
- [6] Koki Inami, Sho Sakaino, and Toshiaki Tsuji. Motion retouch: Motion modification using four-channel bilateral control. In *2025 IEEE International Conference on Mechatronics (ICM)*, pp. 1–6, 2025.
- [7] Yiming Ding, Carlos Florensa, Pieter Abbeel, and Mariano Phielipp. Goal-conditioned imitation learning. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, Vol. 32. Curran Associates, Inc., 2019.
- [8] Tobias Johannink, Shikhar Bahl, Ashvin Nair, Jianlan Luo, Avinash Kumar, Matthias Loskyll, Juan Aparicio Ojea, Eugen Solowjow, and Sergey Levine. Residual reinforcement learning for robot control. In *2019 International Conference on Robotics and Automation (ICRA)*, pp. 6023–6029, 2019.
- [9] Todor Davchev, Kevin Sebastian Luck, Michael Burke, Franziska Meier, Stefan Schaal, and Subramanian Ramamoorthy. Residual learning from demonstration: Adapting dmps for contact-rich manipulation. *IEEE Robotics and Automation Letters*, Vol. 7, No. 2, pp. 4488–4495, 2022.
- [10] Yiou Huang, Ning Ma, Weichu Zhao, Zinuo Liu, Jun Sun, Qiufeng Wang, and Yaran Chen. Force-aware residual dagger via trajectory editing for precision insertion with impedance control, 2026.
- [11] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep Residual Learning for Image Recognition . In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, Los Alamitos, CA, USA, June 2016. IEEE Computer Society.
- [12] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bi-manual manipulation with low-cost hardware, 2023.