

残差 NN による軌道後修正手法の提案と予備実験

—位置制御タスクにおける単調増加性の検証—

水谷 圭（筑波大学 工学システム学類 境界研究室）

1. 研究背景と問題設定

1.1 バイラテラル制御に基づく模倣学習 (BCIL)

四チャンネルバイラテラル制御を用いた模倣学習 (BCIL) は、デモンストレーションデータとして位置と力の両方を含む高品質な軌道を収集できる点で、視覚ベースの行動クローニングに対して優位性を持つ。Bi-ACT [1] は Transformer アーキテクチャを採用し、高い汎化性能を実現している。

1.2 条件変化への対応コスト

実運用ではタスク条件の変化が頻発するが、既存の BCIL には以下の問題がある：

- タスク条件が変わるたびに新規デモ収録と再学習が必要
- 「プレース位置を 5 mm 右にする」等の定量的な数値指定ができない
- 数値目標への収束を保証する機構がない

1.3 研究の問い

ベース軌道に対する差分（残差）だけを予測するモデルを学習すれば、ラベルと出力の間の線形性・単調増加性が強まり、少量データかつ再学習なしで定量的なラベル制御が実現できるのではないか？

1.4 既存手法との比較

→「定量数値ラベルによる位置+力の軌道生成を、少量オフラインデータかつ再学習なしで実現する」手法は既存研究に存在しない。

2. 提案手法の概要と予備実験の位置付け

2.1 三段構成

「数値ラベル c を指定するだけで、ベース軌道から所望の量だけ変化した軌道を生成し、ロボットを自律動作させる」

[図：提案手法の全体フロー（Motion Retouch によるデータ収集 → 残差 NN 学習 → ILC による反復収束）]

- Motion Retouch によるデータ収集**：ベース軌道に対してプレース位置等を修正した軌道を複数収録し、残差 $\Delta\tau^{(k)} = \tau_{\text{corr}}^{(k)} - \tau_{\text{base}}$ とラベル c のペアを得る
- 残差 NN の学習**：フル軌道 τ_{base} とラベル c を入力として補正量 $\Delta\tilde{\tau}$ を一括予測する双方向 Transformer
- 局所線形化 ILC**：Broyden 法でヤコビアン J を逐次推定しながらラベルを更新し、目標値 v^* への収束を保証

$$c^{(k+1)} = c^{(k)} + \gamma (J^{(k)})^\dagger e^{(k)}, \quad e^{(k)} = v^* - v(\tau^{(k+1)})$$

2.2 中核にある仮説

軌道全体を直接予測するより、ベース軌道からの差分だけを予測する方が、ラベルと出力変位の間の線形性・単調増加性が強まる。これが成立すれば、ILC による安定した数値収束が可能になる。

2.3 今回の予備実験の位置付け

完全なシステム（双方向 Transformer + ILC）の実装に先立ち、残差 NN が単調増加性を実際に持てるかどうかを、シンプルな自己回帰モデルを用いた実機実験で検証する。

検証仮説：ラベル $[l_x, l_y]$ を変化させると、実際のプレース変位がそれに追従して単調に変化する（ILC が収束するための前提条件）

3. 予備実験の設定

3.1 タスク

四角い積み木のピックアンドブレース：ロボットアームが積み木を掴み、ラベル $[l_x, l_y]$ （各軸の移動量）に対応した位置に置く。

[図：実験タスクの概要図（9 箇所のプレース位置と移動量ラベルの対応）]

3.2 学習データの収集手順

- ベース動作（「掴んだ積み木をそのまま置く」）を収録
- Motion Retouch により、プレース位置を左右・上下に 9 箇所ずらす修正を各 5 回適用（計 45 本）
- ラベル $[l_x, l_y]$ （各軸の移動量）を付与

これにより、プレース位置指定データとベース軌道に対する残差データの両方を取得している。

3.3 検証モデル

モーションコピー単体 (motion_copy) はハードウェア再現精度の基準として使用。

3.4 検証条件と評価指標

検証ラベル： $\pm 3, \pm 5, \pm 7$ の組み合わせ、計 27 種類 × 各 5 試行（掴み不可ラベルは除外：試行数 direct 105, res_nonImage 116, res 126）

評価指標：

- ラベルと実変位の相関：決定係数 R^2 , Spearman 順位相関 ρ
- $c = [0, 0]$ 指定時の系統バイアス (mean, std)
- 試行間再現性 σ と分散の分解（ハードウェア由来 vs. モデル由来）
- 手先姿勢偏差：geodesic 距離 $\theta = \arccos\left(\frac{\text{tr}(R_{\text{ref}}^\top R) - 1}{2}\right)$

4. 実験結果①：ラベル追従性と系統バイアス

4.1 ラベル追従性（単調増加性の検証）

[図：ラベル vs. 実変位の散布図（左：direct, 中：res, 右：res_nonImage）]

考察：

- res は $\rho \approx 0.94$, $R^2 \approx 0.87$ と高い単調増加性を達成。ILC の前提条件を実験的に支持する結果が得られた
- res_nonImage も $\rho \approx 0.88$ と十分な追従性を示し、画像な

Table 1 既存手法と提案手法の比較

手法	位置+力	定量数値ラベル	再学習不要	オンライン介入不要
Bi-ACT（標準 BCIL） [1]	✓	×	×	✓
Bi-LAT（言語条件付き） [2]	✓	×	△	✓
Goal-conditioned IL [3]	×	△	×	✓
残差 RL [4]	×	×	✓	×
TER-Dagger 等 [5]	✓	×	✓	×
提案手法	✓	✓	✓	✓

Table 2 検証した 3 モデルの比較

モデル名	入力	出力	特徴
direct	関節状態・画像・ラベル	次ステップ関節状態（絶対値）	全関節を NN が予測
res	関節状態・画像・ラベル	次ステップのベース動作への残差	モーションコピー＋ 残差予測
res_nonImage	関節状態・ラベル（画像なし）	同上	res の軽量版

Table 3 ラベルと実変位の相関係数（全試行）

モデル	R^2 (X 軸)	R^2 (Y 軸)	Spearman ρ (X)	Spearman ρ (Y)
direct	≈ 0.50	≈ 0.50	≈ 0.65	≈ 0.65
res	≈ 0.87	≈ 0.87	≈ 0.94	≈ 0.94
res_nonImage	≈ 0.77	≈ 0.77	≈ 0.88	≈ 0.88

し軽量モデルでも有効

- **direct** は $R^2 \approx 0.50$ と弱く、残差予測の枠組みが単調増加性の実現に不可欠であることを示唆
- クロス軸 ($l_x \rightarrow \Delta y$ 等) の R^2 は全モデルで低く、軸間干渉は小さい

4.2 $c = [0, 0]$ 時の系統バイアス

ラベル $[0, 0]$ 指定時のブレース位置と基準点 ($x = 280.1$ mm, $y = -12.2$ mm) からのオフセット:

Table 4 $c = [0, 0]$ 指定時の位置バイアス ($n = 5$)

モデル	bias_{XY} [mm]	σ_{XY} [mm]
motion_copy (HW 上限)	≈ 2.3	≈ 0.4
direct	≈ 8.6	≈ 11.3
res	≈ 18.6	≈ 1.2
res_nonImage	≈ 15.1	≈ 0.8

考察: **res**・**res_nonImage** ともに $c = [0, 0]$ でも 15~19 mm の系統的なオフセットが生じている (モデルが「残差ゼロ」を正確に学習できていない). ILC による収束にはこのバイアスの吸収・補正が必要である.

5. 実験結果②: 試行間再現性と手先姿勢偏差

5.1 試行間再現性と分散の分解

同一ラベル内の試行間分散を以下の独立性仮定のもとで分解した:

$$\sigma_{\text{total}}^2 = \sigma_{\text{copy}}^2 + \sigma_{\text{model}}^2, \quad \sigma_{\text{copy}}^2 \approx 0.13 \text{ mm}^2 \quad (\sigma \approx 0.3 \text{ mm})$$

考察:

- 試行間ばらつきの **87~98%はモデルの推論ばらつき**が原因; ハードウェア ($\sigma \approx 0.3$ mm) はボトルネックではない
- **res_nonImage** は画像除去で $\sigma \approx 1$ mm と大幅に安定 (**res** の $\approx 3\text{--}4$ mm から改善) $\rightarrow$ 画像特徴量のばらつきが推論ノイズを増幅していた可能性

5.2 手先姿勢偏差 (geodesic 距離)

[図: ピック時の geodesic 偏差と l_x の散布図 (**res**, $\rho \approx -0.47$)]

考察:

- 全モデルで基準 ($\approx 1^\circ$) より有意に大きな姿勢偏差 ($5\text{--}9^\circ$) が存在; タスク成功率に影響し得る
- **res** ではピック時の姿勢偏差と l_x の間に $\rho \approx -0.47$ の相関: 残差予測が位置変位だけでなく姿勢変化も学習してしまっている (「ラベルで変えたい成分以外も変わる」問題)
- **res_nonImage** では相関が見られない $\rightarrow$ 画像特徴量が姿勢干渉を媒介している可能性

6. 総合評価と今後の課題

6.1 3モデル比較まとめ

結論: 残差予測の枠組みにより、目標とする単調増加性はある程度実現できることを確認した (**res**: $\rho \approx 0.94$). 一方で、以下2点が明確な課題として浮かび上がった.

6.2 今後の課題と改善方向

課題① $c = 0$ 時の系統バイアス (15~19 mm)

原因仮説: 学習データの分布がオリジナル動作位置を中心に偏っていない.

改善: 損失関数への「残差ゼロ」ペナルティ追加; ILC による反復補正 (理論的には吸収可能)

課題② ラベルが姿勢にも影響 (**res** ピック時 $\rho \approx -0.47$)

原因仮説: 残差 $\Delta\tau$ に位置変化と姿勢変化が混在している.

改善: 損失関数への姿勢固定制約; 補正マスク $\hat{M}$ を $\mathbb{R}^{T \times 1}$ から $\mathbb{R}^{T \times D}$ に拡張して次元別補正を可能にする

次ステップ (フルモデル実装に向けて)

- (1) 双方向 Transformer による一括補正モデルの実装
- (2) Broyden 法 ILC ループとの統合・系統バイアスの吸収実証
- (3) 力情報を含む軌道 (コネクタ挿入, ねじ締め等) への適用

参考文献

- [1] T. Buamane et al. Bi-ACT: Bilateral Control-Based Imitation Learning via Action Chunking with Transformers. 2024 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM). 2024.
- [2] S. Kobayashi et al. Bi-LAT: Bilateral Control-Based Imitation Learning via Natural Language and Action Chunking with Transformers. arXiv preprint arXiv:2504.01301 (2025).
- [3] Y. Ding, C. Florensa, M. Phielipp, and P. Abbeel. Goal-conditioned Imitation Learning. *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 32. 2019.
- [4] T. Johannink, S. Bahl, A. Nair, J. Luo, A. Kumar, M. Luu, A. Srinivas, P. Abbeel, M. Riedmiller, and S. Levine. Residual Reinforcement Learning for Robot Control. 2019 IEEE International Conference on Robotics and Automation (ICRA). 2019, pp. 6023–6029.
- [5] C.-C. Huang et al. TER-DAGger: Force-Aware Residual DAGger via Trajectory Editing for Precision Insertion with Impedance Control. arXiv preprint arXiv:2603.04038 (2025).

Table 5 試行間分散の分解（ハードウェア由来 vs. モデル由来）

モデル	軸	σ^2_{total} [mm ²]	σ^2_{copy} [mm ²]	モデル由来比率	Levene p
res	X	≈ 10–16	≈ 0.13	> 98%	< 0.05
res	Y	≈ 10–16	≈ 0.13	> 98%	< 0.05
res_nonImage	X	≈ 1–2	≈ 0.13	> 87%	< 0.05
res_nonImage	Y	≈ 1–2	≈ 0.13	> 87%	< 0.05

Table 6 プレース・ピック時の手先姿勢偏差

モデル	mean_geo [deg]	std_geo [deg]	ρ （ラベルと姿勢偏差の相関）
motion_copy（基準）	≈ 0.4–1.3	小	≈ 0
direct	≈ 5–9	中	低
res	≈ 5–9	中	ピック時 ≈ −0.47
res_nonImage	≈ 5–9	中	低

Table 7 3モデルの総合比較

指標	direct	res	res_nonImage
ラベル追従性 (R^2)	低 (≈ 0.50)	最高 (≈ 0.87)	高 (≈ 0.77)
単調増加性 (ρ)	低 (≈ 0.65)	最高 (≈ 0.94)	高 (≈ 0.88)
試行間再現性 (σ)	非常に低 (≈ 12 mm)	中 (≈ 3–4 mm)	最高 (≈ 1 mm)
[0, 0] バイアス	中 (≈ 9 mm)	大 (≈ 19 mm)	大 (≈ 15 mm)
姿勢干渉	ランダム誤差	ラベルに相関あり	ランダム誤差